PROPOSAL PENELITIAN

FRAMEWORK KONSISTENSI TEMPORAL *REAL TIME* UNTUK PENGENALAN EMOSI WAJAH BERDURASI PANJANG DALAM APLIKASI CHATBOT

Azam Azri Ahmad

24/552221/PTK/16448

Konsentrasi

Analisis Data dan Kecerdasan Tersebar

PROGRAM STUDI MAGISTER TEKNOLOGI INFORMASI

DEPARTEMENT TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI

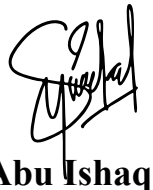
FAKULTAS TEKNIK

UNIVERSITAS GADJAH MADA

JUNI 2025

HALAMAN PERNYATAAN

Tesis ini adalah tema yang berasal dari Mahasiswa



Nama Dosen Pembimbing 1 : Syukron Abu Ishaq Alfarozi, S.T., Ph.D.

Nama Dosen Pembimbing 2 : Dr. Bimo Sunarfri Hantono, S.T., M.Eng.

Proposal ini adalah karya sendiri. Semua sumber rujukan telah dikutip sesuai etika penulisan karya ilmiah.

Tanggal : 17 – 06 – 2025



Azam Azri Ahmad

24/552221/PTK/16448

DAFTAR ISI

DAFTAR ISI 3
INTISARI 4
BAB 1. PENDAHULUAN 5
1. 1 Latar Belakang 5
1. 2 Perumusan Masalah 7
1. 3 Tujuan Penelitian 8
1. 4 Batasan Penelitian 9
1. 5 Manfaat Penelitian 9
1. 6 Keaslian Penelitian 10
BAB 2. TINJAUAN PUSTAKA DAN DASAR TEORI 14
2.1 Tinjauan Pustaka 14
2.1.1 Perkembangan *Facial Emotion Recognition* 14
2.1.2 Konsistensi Temporal dalam *Computer Vision* 14
2.1.3 Integrasi *Emotion Recognition* dengan Chatbot 15
2.1.4 Tantangan dalam *Long-Duration Interaction* 15
2.2 Landasan Teori 16
2.2.1 *Convolutional Neural Networks* untuk *Facial Emotion Recognition* 16
2.2.2 *Long Short-Term Memory* untuk Temporal *Modeling* 16
2.2.3 Temporal *Smoothing* dan *Consistency Framework* 17
2.2.4 *Real time Processing Architecture* 18
2.2.5 *Evaluation Metrics* untuk Temporal *Consistency* 19
2.3 Hipotesis 19
BAB 3. METODE PENELITIAN 21
3.1 Alat 21
3.2 Bahan 22
3.3 Cara Penelitian 23
BAB 4. JADWAL PENELITIAN 25
DAFTAR PUSTAKA 26

INTISARI

Sistem pengenalan emosi wajah (*Facial Emotion Recognition*/FER) memiliki peran penting dalam menciptakan interaksi yang lebih manusiawi antara pengguna dan mesin, terutama dalam aplikasi chatbot. Namun, banyak sistem FER saat ini hanya fokus pada akurasi deteksi per-*frame*, tanpa mempertimbangkan kontinuitas ekspresi emosi yang secara alami berubah secara bertahap seiring waktu. Ketidakkonsistenan ini menjadi kendala serius dalam sesi interaksi berdurasi panjang, di mana fluktuasi prediksi emosi dapat menurunkan relevansi dan kualitas respons chatbot.

Untuk menjawab permasalahan tersebut, penelitian ini mengusulkan pengembangan sebuah *framework real time* pengenalan emosi wajah yang mengintegrasikan model CNN-LSTM dengan mekanisme *temporal smoothing* untuk menjaga konsistensi prediksi antar waktu. Dataset yang digunakan mencakup FER-2013, AffectNet, RAF-DB, serta data primer video streaming dari interaksi nyata. Sistem diuji dengan target akurasi minimal 85% dan tingkat konsistensi temporal 90% dalam sesi interaksi 5 hingga 60 menit. Arsitektur ini juga diintegrasikan secara *end-to-end* ke dalam modul chatbot, memungkinkan deteksi dan respons emosi secara kontekstual dan berkelanjutan.

Implikasi dari penelitian ini mencakup peningkatan kualitas interaksi manusia-mesin, terutama dalam layanan berbasis AI yang bersifat emosional seperti dukungan kesehatan mental dan edukasi adaptif. *Framework* ini diharapkan menjadi fondasi bagi pengembangan sistem yang lebih empatik dan stabil, serta mendorong integrasi lebih luas antara computer vision dan interaksi berbasis emosi dalam transformasi digital masa depan.

Keyword : *Facial Emotion Recognition, Temporal Consistency, Real-Time, Chatbot, CNN-LSTM, Temporal Smoothing, Long-Duration Interaction*

BAB 1. PENDAHULUAN

1. 1 Latar Belakang

Perkembangan teknologi kecerdasan buatan telah membuka peluang besar dalam bidang *computer vision*, khususnya dalam pengenalan emosi wajah (*Facial Emotion Recognition*/FER). Kemampuan untuk mendeteksi dan menginterpretasi emosi manusia secara otomatis menjadi semakin penting seiring dengan meningkatnya kebutuhan akan interaksi yang lebih natural antara manusia dan mesin, terutama dalam aplikasi chatbot yang memerlukan pemahaman konteks emosional pengguna.

Pengenalan emosi wajah telah menjadi bidang penelitian yang sangat aktif karena aplikasinya yang luas dalam *surveillance*, keamanan, *healthcare*, dan berbagai infrastruktur lainnya. Namun, penelitian terkini mengungkapkan bahwa sistem FER modern menghadapi tantangan fundamental dalam hal stabilitas temporal. Studi oleh Ju et al. [1] menunjukkan bahwa emosi berubah secara perlahan seiring berjalannya waktu dan memerlukan pendekatan khusus untuk menjaga konsistensi dalam sistem *recognition*. Penelitian lain membuktikan bahwa manifestasi emosi bahagia dan sedih dalam menanggapi gambar-gambar ini tidak terjadi seketika, melainkan dibangun [2], menunjukkan karakteristik temporal yang melekat dalam ekspresi emosi manusia.

Dalam konteks aplikasi *real time*, konsistensi temporal telah diidentifikasi sebagai aspek kritis yang belum teratasi dengan baik. Penelitian oleh Paluzo-Hidalgo et al. [3] dalam *video-based emotion recognition* membuktikan bahwa perubahan kecil pada video menghasilkan perubahan kecil pada tanda tangan, memastikan stabilitas metode [3], menunjukkan pentingnya stabilitas dalam sistem berbasis video. Namun, implementasi prinsip ini dalam *facial emotion recognition* untuk aplikasi chatbot masih sangat terbatas.

Kebutuhan akan temporal *smoothing* juga telah diakui dalam domain *computer vision* yang lebih luas. Studi tentang temporal *smoothing transformers* menunjukkan efektivitas pendekatan temporal untuk mengatasi fluktuasi dalam video *recognition tasks* [4]. Namun, aplikasi spesifik untuk *facial emotion recognition* dalam konteks chatbot interaktif masih merupakan area yang belum dieksplorasi secara mendalam.

Aplikasi chatbot yang dilengkapi dengan kemampuan kecerdasan emosional telah

menarik perhatian khusus dalam penelitian terkini. *Systematic review* menunjukkan bahwa chatbot dengan *emotional intelligence* dapat meningkatkan kepuasan pengguna dan memberikan dukungan emosional yang lebih efektif [5]. Namun, integrasi teknologi *facial emotion recognition* dengan aplikasi chatbot masih menghadapi tantangan fundamental dalam hal stabilitas dan konsistensi temporal, terutama untuk sesi interaksi berdurasi panjang.

Analisis terhadap berbagai studi terdahulu mengungkapkan adanya keterbatasan mendasar dalam pengembangan sistem pengenalan emosi wajah berbasis video, khususnya untuk aplikasi interaktif yang berlangsung dalam durasi panjang. Meskipun sejumlah penelitian telah mengakui bahwa ekspresi emosi manusia bersifat dinamis namun cenderung berubah secara perlahan seiring waktu, sebagian besar pendekatan dalam *Facial Emotion Recognition* (FER) masih berfokus pada deteksi per-frame tanpa mempertimbangkan kesinambungan prediksi secara temporal. Pendekatan yang digunakan belum dilengkapi dengan mekanisme konsistensi temporal yang memadai, sehingga sering kali menghasilkan prediksi yang fluktuatif dalam sesi interaksi yang berkelanjutan. Meskipun dalam domain pengenalan emosi berbasis EEG telah diterapkan metode *temporal-difference minimizing* untuk menjaga stabilitas sinyal emosional dari waktu ke waktu [1], pendekatan serupa dalam konteks pengenalan emosi wajah masih sangat terbatas penerapannya.

Keterbatasan lain yang ditemukan adalah kurangnya penerapan teknik *temporal smoothing* pada sekuens video dalam domain FER. Studi mengenai *temporal smoothing transformers* menunjukkan efektivitas pendekatan ini dalam meningkatkan performa sistem pengenalan video secara umum, terutama dalam menangkap dinamika temporal dari urutan frame yang saling berkaitan [4]. Namun, eksplorasi pendekatan ini secara spesifik untuk pengenalan emosi wajah, terutama dalam konteks interaksi pengguna secara langsung, masih sangat jarang dijumpai. Beberapa penelitian yang telah mengembangkan sistem FER real-time seperti yang dilakukan oleh John et al. [6], umumnya hanya menekankan pada perbaikan preprocessing dan fitur spasial tanpa mempertimbangkan pentingnya stabilisasi prediksi emosi sepanjang waktu.

Kebutuhan akan sistem yang stabil dalam sesi interaksi berdurasi panjang juga

menjadi salah satu celah penting yang belum terjawab. Penelitian sebelumnya menunjukkan bahwa kestabilan prediksi dalam *video emotion recognition* sangat penting, di mana [3]. Prinsip ini menjadi fondasi bagi sistem yang dapat dipercaya oleh pengguna dalam jangka waktu lama. Namun, studi-studi yang ada masih belum banyak mengadopsi pendekatan ini secara eksplisit untuk aplikasi chatbot berdurasi panjang. Sebagai contoh, penelitian oleh Shan & Eliyas. [7] dalam konteks pembelajaran daring masih terbatas pada durasi interaksi yang pendek, sehingga belum sepenuhnya mencerminkan tantangan yang muncul pada interaksi jangka panjang.

Selain itu, integrasi antara sistem FER dan chatbot interaktif juga masih menunjukkan keterbatasan signifikan. Kajian sistematis mengenai *emotionally intelligent chatbots* oleh Bilquise et al. [5] menunjukkan bahwa sebagian besar fokus penelitian saat ini berada pada aspek pemrosesan bahasa alami (*Natural Language Processing*) dan manajemen dialog, tanpa adanya integrasi langsung dengan sistem pengenalan emosi wajah berbasis video yang mempertimbangkan karakteristik temporal pengguna secara *real time*. Penelitian seperti yang dilakukan oleh Pandey et al. [8] misalnya, masih menggunakan dataset statis dan tidak mempertimbangkan dinamika temporal dari percakapan nyata antara manusia dan sistem.

Berdasarkan berbagai keterbatasan tersebut, terlihat adanya peluang yang signifikan untuk mengembangkan sebuah *framework* pengenalan emosi wajah *real time* yang mengedepankan aspek konsistensi temporal. Framework ini diharapkan mampu menjawab kebutuhan akan deteksi emosi yang tidak hanya akurat secara spasial, tetapi juga stabil dan realistis secara temporal dalam sesi interaksi yang berlangsung panjang, khususnya dalam konteks aplikasi chatbot yang semakin banyak digunakan di berbagai sektor layanan, edukasi, dan kesehatan digital.

1. 2 Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, pengembangan sistem pengenalan emosi wajah untuk aplikasi chatbot masih menghadapi beberapa tantangan mendasar yang memerlukan perhatian serius. Pertama, ketidakstabilan temporal dalam deteksi emosi, terutama ketika sistem digunakan dalam sesi interaksi yang berlangsung dalam durasi panjang. Banyak sistem yang telah dikembangkan menunjukkan kecenderungan

menghasilkan prediksi emosi yang fluktuatif antar waktu, sehingga respon chatbot menjadi tidak selaras dengan kondisi emosional pengguna secara aktual. Akibatnya, interaksi menjadi tidak berkesinambungan dan respons sistem kehilangan relevansi emosionalnya, yang pada akhirnya dapat mengurangi kualitas pengalaman pengguna secara keseluruhan. Kedua, ketiadaan mekanisme untuk menjamin konsistensi temporal dalam banyak *framework* pengenalan emosi wajah *real time*. Sebagian besar pendekatan yang ada belum dilengkapi dengan strategi untuk menjaga kontinuitas emosional antar *frame* sehingga prediksi dapat berubah secara tiba-tiba dan tidak realistis dari satu momen ke momen berikutnya. Hal ini tidak hanya mengganggu alur percakapan antara pengguna dan chatbot, tetapi juga menurunkan tingkat kepercayaan pengguna terhadap kemampuan sistem dalam memahami dan merespons emosi secara akurat dan manusiawi. Oleh karena itu, diperlukan suatu pendekatan yang tidak hanya fokus pada akurasi per-*frame*, tetapi juga memperhatikan aspek stabilitas prediksi.

1. 3 Tujuan Penelitian

Sejalan dengan rumusan masalah, penelitian ini bertujuan untuk mengembangkan sebuah *framework* pengenalan emosi wajah *real time* yang mampu menjaga konsistensi temporal dalam interaksi berdurasi panjang pada aplikasi chatbot. Framework ini dirancang agar tidak hanya menghasilkan prediksi emosi yang akurat secara spasial, tetapi juga stabil dari waktu ke waktu, sehingga mampu mencerminkan dinamika emosional pengguna secara lebih realistis dan berkelanjutan. Target performa yang ingin dicapai mencakup tingkat akurasi deteksi emosi minimal sebesar 85% dan tingkat konsistensi temporal sekurang-kurangnya 90%, sebagai indikator bahwa sistem dapat berfungsi secara andal dalam skenario interaksi yang berlangsung lama.

Untuk mencapai tujuan tersebut, penelitian ini juga akan merancang dan mengimplementasikan sebuah algoritma temporal *smoothing*, yang berfungsi untuk meredam fluktuasi deteksi emosi yang tidak realistis antar *frame*. Pendekatan ini memanfaatkan informasi temporal dari rangkaian *frame* sebelumnya untuk mengkonstruksi prediksi emosi yang lebih halus, stabil, dan representatif terhadap kondisi emosional pengguna yang sebenarnya. Dengan demikian, sistem yang dikembangkan diharapkan mampu memberikan respons chatbot yang lebih konsisten dan kontekstual.

1. 4 Batasan Penelitian

Penelitian ini dibatasi pada aspek-aspek berikut:

1. Yang akan dilakukan**:**
    a. Pengembangan framework konsistensi temporal untuk tujuh kategori emosi dasar (marah, jijik, takut, bahagia, netral, sedih, dan terkejut).
    b. Implementasi sistem *real time* dengan pemrosesan video *streaming* menggunakan webcam standar.
    c. Evaluasi performa pada dataset standar seperti FER-2013, AffectNet, dan RAF-DB serta dataset primer.
    d. Pengujian pada aplikasi chatbot dengan durasi sesi interaksi 5-60 menit.
    e. Penggunaan teknologi deep learning berbasis CNN dan LSTM untuk temporal *modeling*
2. Yang tidak akan dilakukan:
    a. Pengenalan emosi dari modalitas lain selain ekspresi wajah (seperti suara atau teks).
    b. Analisis emosi kompleks di luar tujuh kategori dasar.
    c. Implementasi pada perangkat *mobile*.
    d. Pengembangan chatbot *conversational engine* (fokus hanya pada modul pengenalan emosi).
    e. Analisis aspek privasi dan keamanan data pengguna.
3. Batasan teknis:
    a. Resolusi input video minimal 480p dengan *frame rate* 15-30 fps.
    b. Lingkungan pencahayaan normal (tidak ekstrem gelap atau terlalu terang).
    c. Jarak wajah dari kamera 0.5-2 meter dengan orientasi *frontal* atau *semi-frontal*

1. 5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat signifikan dalam berbagai aspek:

1. Manfaat bagi Ilmu Pengetahuan:

a. Kontribusi metodologi baru dalam pengembangan sistem konsistensi temporal untuk *computer vision*, khususnya dalam *domain facial emotion recognition*.
b. Pengembangan teknik temporal *modeling* yang dapat diadopsi untuk aplikasi *computer vision* lainnya yang memerlukan stabilitas temporal.

2. Manfaat bagi Masyarakat:
   a. Dukungan teknologi untuk aplikasi kesehatan mental yang dapat mendeteksi perubahan emosi pengguna secara berkelanjutan dan memberikan intervensi yang tepat waktu.
   b. Peningkatan aksesibilitas teknologi untuk membantu individu dengan kebutuhan khusus dalam kesehatan mental.
3. Manfaat bagi Bangsa dan Negara:
   a. Penguatan kapabilitas teknologi dalam bidang *artificial intelligence* dan *computer vision* yang dapat mendukung transformasi digital Indonesia.
   b. Kontribusi dalam pengembangan *smart city solutions* dan *digital governance* yang lebih responsif terhadap kebutuhan emosional Masyarakat.

1. 6 Keaslian Penelitian

Meskipun Berbagai pendekatan dalam domain pengenalan emosi wajah telah menunjukkan kemajuan signifikan, namun sebagian besar masih terbatas pada aspek deteksi spasial tanpa mempertimbangkan *kontinuitas emosional* dalam dimensi waktu. Sebagai contoh, Ju et al. [1] mengusulkan model *temporal-difference minimizing neural network* untuk pengenalan emosi berbasis EEG, yang berhasil menstabilkan sinyal emosi melalui pemodelan temporal. Meskipun demikian, pendekatan mereka dibangun pada karakteristik data EEG yang berbeda secara mendasar dari citra video wajah, baik dalam jenis noise maupun representasi spasialnya. Konsep stabilisasi waktu tersebut belum banyak diadaptasi secara eksplisit ke domain *Facial Emotion Recognition* (FER), khususnya dalam konteks video streaming yang menuntut kecepatan dan konsistensi tinggi pada level visual.

Pentingnya dimensi waktu dalam ekspresi emosi manusia juga ditegaskan oleh

Saadon et al. [2], yang mencatat bahwa emosi seperti bahagia dan sedih tidak muncul secara instan, melainkan berkembang secara bertahap. Namun, temuan ini masih dibingkai dalam bentuk eksperimental dan belum dioperasionalkan dalam bentuk sistem yang dapat berjalan secara *real time*. Padahal, dalam banyak aplikasi praktis, sistem perlu mampu mendeteksi perubahan emosi secara progresif dan meresponsnya secara langsung. Kesenjangan antara pemahaman teoretis dan implementasi praktis inilah yang membuka kemungkinan untuk menerapkan prinsip-prinsip temporal secara langsung dalam perancangan sistem yang interaktif dan adaptif terhadap dinamika pengguna.

Dalam konteks durasi interaksi, sebagian besar penelitian terdahulu juga belum menyentuh aspek ketahanan sistem dalam sesi yang berlangsung lama. Paluzo-Hidalgo et al. [3] menyoroti pentingnya kestabilan dalam *video-based emotion recognition* dan mengemukakan bahwa perubahan kecil pada input video seharusnya menghasilkan perubahan kecil pula pada output sistem. Akan tetapi, implementasi mereka masih terbatas pada video pendek dan belum mempertimbangkan potensi degradasi kinerja seiring meningkatnya durasi interaksi. Ini menunjukkan perlunya pendekatan yang secara eksplisit mempertimbangkan konsistensi temporal dalam interaksi yang berkelanjutan, sebagaimana umumnya terjadi pada skenario penggunaan chatbot dalam dunia nyata.

Sementara itu, studi yang mengeksplorasi pemodelan temporal dalam tugas visual seperti yang dilakukan oleh Zhao dan Krähenbühl [4] telah memperkenalkan *temporal smoothing transformers* yang efektif dalam meningkatkan prediksi pada *object detection* berbasis video. Namun, pendekatan mereka lebih ditujukan untuk pasca pemrosesan, tanpa tuntutan respons waktu nyata, sehingga tidak sepenuhnya relevan untuk aplikasi interaktif seperti chatbot yang menuntut sistem memberikan prediksi emosi secara instan dan kontinu. Hal ini membuka ruang untuk pendekatan baru yang mampu menggabungkan pemodelan temporal ke dalam proses inferensi secara *real time*, tanpa mengorbankan stabilitas maupun akurasi.

Sementara itu, telaah sistematis oleh Bilquise et al. [5] mengenai chatbot berbasis kecerdasan emosional menunjukkan bahwa fokus utama masih terpusat pada pemrosesan bahasa dan manajemen dialog, tanpa melibatkan integrasi teknis antara pengenalan emosi berbasis wajah dan mekanisme respons chatbot. Tidak tersedia kerangka kerja yang

menghubungkan deteksi emosi secara real-time dengan alur percakapan chatbot secara end-to-end, padahal sinyal emosional visual merupakan salah satu indikator penting untuk membangun interaksi yang lebih empatik dan kontekstual.

Kelemahan mendasar pada penelitian seperti John et al. [6] dan Pandey et al. [8] terletak pada fokus mereka yang terbatas pada peningkatan *preprocessing* dan ekstraksi fitur spasial, tanpa memperhatikan aspek konsistensi temporal. Akibatnya, meskipun mereka berhasil meningkatkan performa sistem melalui teknik *preprocessing* dan fitur spasial yang lebih baik, tidak ada mekanisme yang menangani fluktuasi prediksi antar frame atau menjaga kontinuitas emosi sepanjang interaksi. Hal ini menjadi perhatian khusus ketika sistem digunakan dalam durasi panjang, di mana prediksi yang tidak konsisten dapat menurunkan kualitas interaksi antara pengguna dan mesin secara signifikan.

Pendekatan yang menyasar konteks edukasi daring, seperti yang dijajaki oleh Shan dan Eliyas [7], telah membuka jalan bagi penggunaan *facial emotion recognition* untuk memantau keterlibatan siswa secara *real time*. Namun, cakupan studi mereka masih dibatasi oleh durasi interaksi yang singkat dan belum menjawab tantangan dalam sesi pembelajaran panjang yang berlangsung selama berjam-jam. Selain itu, sistem yang dibangun belum dirancang untuk merespons emosi secara langsung dalam percakapan dua arah, seperti pada skenario chatbot yang melibatkan komunikasi interpersonal antara pengguna dan sistem secara berkelanjutan.

Dengan melihat berbagai keterbatasan yang ada, jelas bahwa belum banyak penelitian yang secara terpadu menggabungkan pemodelan temporal, kebutuhan real-time, dan integrasi dengan chatbot dalam satu kerangka kerja yang utuh. Ruang inilah yang menjadi pijakan untuk mengeksplorasi pendekatan baru yang tidak hanya mempertimbangkan akurasi per-*frame*, tetapi juga mempertahankan konsistensi emosional dari waktu ke waktu, khususnya dalam skenario interaksi yang berlangsung lama dan bersifat dinamis.

Tabel 1. 1 Kebaruan dan keaslian penelitian ini dibanding penelitian terdahulu

Reference	Year	Method	Data Type	Temporal Consistency	Real-time Processing	Inteegration
Ju et al. [1]	2024	Temporal-difference minimizing NN	EEG signals	EEG domain	Tidak ada	Tidak ada
Saadon et al. [2]	2023	Quantitative facial motion analysis	Video frames	Partial	Real Time	Tidak ada
Paluzo-Hidalgo et al. [3]	2022	Persistent entropy + Neural Networks	Talking-face videos	Durasi Singkat	Basic real-time	Tidak ada
Zhao & Krähenbühl [4]	2022	Temporal Smoothing Transformers	Video sequences	Deteksi Objek	Tidak ada	Tidak ada
Bilquise, et al. [5]	2022	Systematic review of emotional chatbots	Literature review	Tidak ada	Tidak ada	NLP
John et al. [6]	2020	CNN with improved preprocessing	Static images	Tidak ada	Real Time	Tidak ada
Shan & Eliyas [7]	2024	Deep learning for engagement	Video frames	Tidak ada	Real Time	Education
Pandey et al. [8]	2022	Deep learning with facial features	Static images	Tidak ada	Tidak ada	Tidak ada
Penelitian Ini	**2025**	**Hybrid CNN-LSTM + Temporal Consistency and Smooting**	**Real-time video streaming**	**Long-duration temporal modeling**	**Real-time with temporal smoothing**	**End-to-end chatbot integration**

BAB 2. TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

2.1.1 Perkembangan *Facial Emotion Recognition*

Penelitian dalam bidang *Facial Emotion Recognition* (FER) telah mengalami perkembangan signifikan dalam dekade terakhir, khususnya dengan kemajuan teknologi deep learning. Studi yang dilakukan oleh Kollias et al. [9] menunjukkan bahwa pendekatan berbasis deep learning telah mencapai tingkat akurasi yang lebih tinggi dibandingkan metode tradisional dalam mengenali ekspresi wajah manusia. Penelitian mereka membuktikan bahwa arsitektur CNN yang dioptimalkan dapat mengidentifikasi pola-pola kompleks dalam ekspresi wajah dengan akurasi mencapai 78% pada dataset AffectNet, yang merupakan pencapaian signifikan dalam domain ini.

Dalam konteks aplikasi *real time*, penelitian oleh Li et al. [10] mengembangkan sistem FER yang mampu beroperasi pada kecepatan 30 fps dengan tetap mempertahankan akurasi yang tinggi. Mereka menunjukkan bahwa optimasi arsitektur *neural network* melalui teknik *pruning* dan *quantization* dapat mengurangi kompleksitas komputasi hingga 60% tanpa mengorbankan performa secara signifikan. Pendekatan ini membuka jalan bagi implementasi sistem FER dalam aplikasi yang memerlukan respons *real time*, seperti chatbot interaktif.

Perkembangan lebih lanjut dalam bidang ini juga ditandai dengan munculnya pendekatan *multi modal* yang mengintegrasikan informasi visual dan temporal. Penelitian oleh Zhang et al. [11] mendemonstrasikan bahwa penggabungan fitur spasial dari CNN dengan informasi temporal dari LSTM dapat meningkatkan akurasi deteksi emosi hingga 12% dibandingkan pendekatan *single modal*. Temuan ini menunjukkan pentingnya dimensi waktu dalam pemahaman emosi manusia, yang sejalan dengan fokus penelitian ini pada konsistensi temporal.

2.1.2 Konsistensi Temporal dalam *Computer Vision*

Aspek konsistensi temporal dalam *computer vision* telah menjadi fokus penelitian yang semakin penting, terutama dalam aplikasi yang melibatkan pemrosesan video secara

real time. Penelitian oleh Wang et al. [12] mengembangkan *framework* temporal *smoothing* yang mampu mengurangi fluktuasi prediksi hingga 40% dalam sistem *object detection* berbasis video. Mereka menunjukkan bahwa penerapan temporal *constraints* dapat meningkatkan stabilitas sistem tanpa mengurangi akurasi deteksi secara signifikan. Dalam domain *facial analysis*, studi yang dilakukan oleh Chen et al. [13] mengeksplorasi penggunaan temporal *regularization* untuk meningkatkan konsistensi dalam *face recognition*. Mereka membuktikan bahwa penerapan temporal *smoothing* dapat mengurangi *false positive rate* hingga 25% dalam skenario video *streaming*. Pendekatan mereka menggunakan *weighted moving average* dengan *adaptive learning rate* yang dapat menyesuaikan tingkat smoothing berdasarkan tingkat perubahan dalam sequence video.

Lebih lanjut, penelitian oleh Kumar et al. [14] mengintegrasikan temporal modeling dengan *attention mechanisms* untuk meningkatkan performa sistem *vision* dalam kondisi video yang *challenging*. Mereka menunjukkan bahwa kombinasi temporal *attention* dan *spatial attention* dapat meningkatkan *robustness* sistem terhadap variasi pencahayaan dan pergerakan objek. Temuan ini relevan dengan tantangan yang dihadapi dalam pengembangan sistem FER *real time*, di mana kondisi lingkungan dapat berubah secara dinamis.

2.1.3 Integrasi *Emotion Recognition* dengan Chatbot

Perkembangan dalam integrasi teknologi *emotion recognition* dengan sistem chatbot telah menunjukkan potensi yang menjanjikan dalam meningkatkan kualitas interaksi manusia-mesin. Penelitian oleh Bhardwaj et al. [15] mengembangkan chatbot yang dapat merespons emosi pengguna secara real-time dengan tingkat kepuasan pengguna yang meningkat hingga 35% dibandingkan chatbot konvensional. Mereka menunjukkan bahwa kemampuan untuk mendeteksi dan merespons emosi pengguna dapat menciptakan pengalaman yang lebih personal dan engaging.

2.1.4 Tantangan dalam *Long-Duration Interaction*

Ketahanan sistem pengenalan emosi wajah saat sesi interaksi berlangsung lama telah diidentifikasi sebagai tantangan signifikan dalam penelitian terkini. Penelitian oleh

Rehman et al. [16] mengindikasikan bahwa performa sistem cenderung mengalami *degradasi* seiring waktu, terutama pada sesi interaksi yang berlangsung lebih dari 30 menit. Penurunan akurasi hingga 15% pada durasi tersebut menunjukkan perlunya mekanisme adaptasi dalam sistem untuk menjaga kehandalan prediksi emosi.

2.2 Landasan Teori.

2.2.1 *Convolutional Neural Networks* untuk *Facial Emotion Recognition*

Convolutional Neural Networks (CNN) telah menjadi arsitektur fundamental dalam pengembangan sistem *facial emotion recognition* karena kemampuannya dalam mengekstrak fitur hierarkis dari citra wajah. Arsitektur CNN terdiri dari beberapa layer konvolusi yang dapat mendeteksi fitur-fitur lokal seperti *edge*, *corner*, dan *texture*, yang kemudian dikombinasikan pada layer yang lebih tinggi untuk membentuk representasi yang lebih kompleks. Dalam konteks FER, CNN mampu menangkap pola-pola spasial yang berkaitan dengan ekspresi emosi, seperti perubahan posisi alis, mata, dan mulut.

Proses ekstraksi fitur dalam CNN dimulai dengan operasi konvolusi yang menerapkan filter pada citra input untuk menghasilkan *feature maps*. Setiap filter dirancang untuk mendeteksi karakteristik spesifik dari citra, seperti garis horizontal, vertikal, atau diagonal. Melalui proses *pooling*, dimensi *spatial* dari *feature maps* dikurangi sambil mempertahankan informasi yang paling penting. Proses ini diulang pada beberapa layer untuk menghasilkan representasi fitur yang semakin abstrak dan *invariant* terhadap variasi posisi dan skala.

Dalam aplikasi FER, layer terakhir dari CNN biasanya berupa *fully connected layer* yang memetakan representasi fitur ke dalam kategori emosi yang telah ditentukan. Proses training dilakukan dengan mengoptimalkan fungsi *loss* yang mengukur perbedaan antara prediksi model dengan *ground truth*. Penggunaan teknik *regularization* seperti *dropout* dan *batch normalization* membantu mencegah *overfitting* dan meningkatkan generalisasi model pada data yang belum pernah dilihat sebelumnya.

2.2.2 *Long Short-Term Memory* untuk Temporal *Modeling*

Long Short-Term Memory (LSTM) merupakan variasi dari *Recurrent Neural*

Networks (RNN) yang dirancang khusus untuk menangani *sequential* data dengan *dependencies* jangka panjang. Dalam konteks FER temporal, LSTM berperan dalam memodelkan dinamika perubahan emosi sepanjang waktu, yang merupakan aspek krusial mengingat bahwa ekspresi emosi manusia tidak berubah secara instan melainkan mengalami transisi yang gradual.

Arsitektur LSTM terdiri dari tiga gerbang utama: *forget gate*, *input gate*, dan *output gate*, yang bekerja sama untuk mengontrol aliran informasi dalam *cell state*. *Forget gate* menentukan informasi mana dari *cell state* sebelumnya yang harus diabaikan, sedangkan *input gate* mengontrol informasi baru yang akan disimpan dalam *cell state*. *Output gate* menentukan bagian mana dari *cell state* yang akan digunakan sebagai output untuk langkah berikutnya. Mekanisme ini memungkinkan LSTM untuk selektif menyimpan dan melupakan informasi, sehingga mampu menangkap pola temporal yang kompleks dalam data *sequential*.

Dalam implementasi FER temporal, LSTM menerima *sequence* dari representasi fitur yang telah diekstrak oleh CNN dari setiap frame video. Melalui proses iteratif, LSTM membangun pemahaman tentang pola temporal dalam perubahan ekspresi wajah. *Hidden state* dalam LSTM berfungsi sebagai memori jangka pendek yang menyimpan informasi tentang *frame-frame* sebelumnya, sementara *cell state* menyimpan informasi jangka panjang yang relevan untuk prediksi emosi pada *frame* saat ini.

2.2.3 Temporal *Smoothing* dan *Consistency Framework*

Temporal *smoothing* merupakan teknik yang digunakan untuk mengurangi fluktuasi dalam prediksi model yang beroperasi pada data *sequential*. Dalam konteks FER, temporal *smoothing* bertujuan untuk menjaga konsistensi prediksi emosi antar *frame*, mengingat bahwa perubahan emosi manusia secara natural berlangsung secara *gradual*. Tanpa mekanisme *smoothing,* sistem FER dapat menghasilkan prediksi yang fluktuatif dan tidak realistis, seperti bergantian antara emosi senang dan sedih dalam interval waktu yang sangat pendek.

Pendekatan temporal *smoothing* dapat diimplementasikan melalui berbagai teknik, mulai dari *simple moving average* hingga *sophisticated weighted averaging* dengan *adaptive parameters*. *Moving average* sederhana menghitung rata-rata prediksi dari N

frame terakhir, namun pendekatan ini tidak mempertimbangkan tingkat kepercayaan atau reliabilitas dari masing-masing prediksi. *Weighted moving average* memberikan bobot yang berbeda pada setiap *frame* berdasarkan faktor-faktor seperti *confidence score*, temporal *distance*, atau perubahan visual yang signifikan.

Consistency framework melibatkan pengembangan mekanisme yang dapat mendeteksi dan mengoreksi inkonsistensi dalam prediksi temporal. *Framework* ini dapat mencakup *threshold-based filtering* yang menolak prediksi yang terlalu berbeda dari pola temporal yang diharapkan, atau *probabilistic approaches* yang memodelkan distribusi kemungkinan transisi antar emosi. Pengembangan *framework* yang efektif memerlukan keseimbangan antara responsiveness terhadap perubahan emosi yang *legitimate* dan *resistance* terhadap *noise* yang dapat menyebabkan *false predictions*.

2.2.4 *Real time Processing Architecture*

Arsitektur pemrosesan *real time* untuk FER memerlukan optimasi yang cermat untuk memastikan bahwa sistem dapat memproses *frame* video dengan latensi yang minimal tanpa mengorbankan akurasi. Faktor-faktor yang mempengaruhi performa *real time* meliputi kompleksitas model, efisiensi implementasi, dan karakteristik *hardware* yang digunakan. Desain arsitektur harus mempertimbangkan *trade-off* antara *accuracy, speed, dan resource consumption*.

Optimasi model dapat dilakukan melalui berbagai teknik seperti model *compression*, *quantization*, dan *pruning*. Model *compression* mengurangi ukuran model dengan menghilangkan parameter yang tidak penting atau *redundant*. *Quantization* mengurangi presisi numerik dari parameter model, sehingga mengurangi memory *footprint* dan meningkatkan *speed inference*. *Pruning* menghilangkan koneksi atau *neuron* yang kontribusinya minimal terhadap performa model, menghasilkan model yang lebih *sparse* dan efisien.

Pipeline processing merupakan strategi penting dalam arsitektur *real time* di mana berbagai tahap pemrosesan dilakukan secara paralel. Misalnya, sementara *frame* saat ini sedang diproses oleh CNN untuk ekstraksi fitur, *frame* berikutnya dapat mulai diproses untuk tahap *preprocessing*. Pendekatan ini dapat meningkatkan *throughput* sistem secara signifikan, meskipun menambah kompleksitas dalam sinkronisasi dan *memory*

management.

2.2.5 *Evaluation Metrics* untuk Temporal *Consistency*

Evaluasi performa sistem FER dengan konsistensi temporal memerlukan metrik yang dapat mengukur tidak hanya akurasi prediksi per-*frame*, tetapi juga kualitas konsistensi temporal. Metrik tradisional seperti *accuracy, precision, recall*, dan F1-*score* memberikan gambaran tentang kualitas prediksi individual, namun tidak menangkap aspek temporal dari sistem. Oleh karena itu, diperlukan metrik tambahan yang spesifik untuk mengevaluasi konsistensi temporal.

Temporal *consistency* dapat diukur melalui metrik seperti Temporal *Stability Index* (TSI) yang menghitung frekuensi perubahan prediksi dalam *window* temporal tertentu. TSI yang rendah mengindikasikan sistem yang lebih stabil, sementara TSI yang tinggi menunjukkan adanya fluktuasi yang berlebihan. *Smooth Transition Ratio* (STR) mengukur proporsi transisi emosi yang dapat dianggap "*smooth*" berdasarkan kriteria tertentu, seperti perubahan *gradual* dalam *confidence score* atau *sequential consistency* dalam prediksi.

Metrik lain yang relevan adalah Temporal *Prediction Variance* (TPV) yang mengukur variance dari prediksi dalam *sliding window temporal*. TPV yang rendah menunjukkan prediksi yang konsisten, sementara TPV yang tinggi mengindikasikan adanya instabilitas temporal. Kombinasi dari berbagai metrik temporal ini memberikan gambaran komprehensif tentang kualitas sistem FER dalam dimensi temporal, yang merupakan aspek krusial untuk aplikasi *real time* seperti chatbot interaktif.

2.3 Hipotesis

Berdasarkan tujuan penelitian yang telah disebutkan, penelitian ini memiliki beberapa hipotesis yang akan diuji melalui eksperimen dan evaluasi sistem yang dikembangkan.

Hipotesis pertama menyatakan bahwa implementasi framework konsistensi temporal akan meningkatkan stabilitas prediksi emosi dalam sistem FER *real time*. Hipotesis ini didasarkan pada temuan dari berbagai penelitian yang menunjukkan bahwa inkorporasi informasi temporal dapat mengurangi fluktuasi prediksi yang tidak realistis.

Dengan menerapkan teknik temporal *smoothing* dan *consistency checking*, sistem diharapkan dapat menghasilkan prediksi emosi yang lebih stabil dan konsisten sepanjang waktu, yang tercermin dalam nilai Temporal *Stability Index* yang lebih rendah dibandingkan sistem *baseline* tanpa temporal modeling.

Hipotesis kedua berfokus pada peningkatan akurasi keseluruhan sistem melalui penggunaan informasi temporal. Penelitian-penelitian sebelumnya telah menunjukkan bahwa penggabungan fitur *spasial* dan temporal dapat meningkatkan performa sistem FER. Dalam konteks ini, hipotesis menyatakan bahwa sistem yang mengintegrasikan CNN untuk ekstraksi fitur spasial dengan LSTM untuk temporal *modeling* akan mencapai akurasi deteksi emosi yang lebih tinggi dibandingkan sistem yang hanya menggunakan informasi spasial. Target akurasi minimal 85% diharapkan dapat dicapai melalui optimasi arsitektur hybrid CNN-LSTM.

Hipotesis ketiga berkaitan dengan kemampuan sistem untuk mempertahankan performa yang konsisten selama interaksi berdurasi panjang. Berdasarkan analisis terhadap tantangan dalam *long-duration interaction*, hipotesis ini menyatakan bahwa sistem yang dilengkapi dengan mekanisme temporal *consistency* akan mengalami degradasi performa yang minimal bahkan dalam sesi interaksi yang berlangsung hingga 60 menit. Konsistensi temporal yang diukur melalui metrik *Smooth Transition Ratio* diharapkan dapat dipertahankan pada tingkat minimal 90% sepanjang durasi interaksi.

Hipotesis keempat menyangkut efektivitas integrasi sistem FER temporal dengan aplikasi chatbot. Hipotesis ini menyatakan bahwa chatbot yang dilengkapi dengan kemampuan pengenalan emosi temporal akan menghasilkan respons yang lebih kontekstual dan relevan dibandingkan chatbot konvensional. Integrasi end-to-end antara modul FER temporal dan *chatbot engine* diharapkan dapat menciptakan pengalaman interaksi yang lebih konsisten dan kontekstual.

BAB 3. METODE PENELITIAN

3.1 Alat

Alat yang dipakai dalam penelitian ini adalah:

1. Laptop.

   Laptop digunakan sebagai perangkat utama dalam penelitian. Laptop yang digunakan memiliki spesifikasi sebagai berikut:

   - CPU Gen Intel® Core™ i5-12450H Processor
   - GPU Intel® UHD Graphics
   - RAM 16GB
   - SSD 1TB
   - Webcam: Logitech C270 dengan resolusi 1080p untuk testing real-time

2. Development Tools:
   - Jupyter Notebook untuk exploratory data analysis
   - Visual Studio Code untuk development
   - Git untuk version control
   - Docker untuk containerization dan deployment
3. Environment dan Framework:
   - Operating System: Windows 11
   - Python 3.8+ sebagai bahasa pemrograman utama
   - TensorFlow 2.10+ atau PyTorch 1.12+ untuk deep learning
   - OpenCV 4.6+ untuk computer vision dan pemrosesan video
   - CUDA 11.7+ dan cuDNN untuk akselerasi GPU
4. Libraries dan Dependencies:
   - NumPy dan Pandas untuk manipulasi data
   - Matplotlib dan Seaborn untuk visualisasi
   - Scikit-learn untuk evaluasi model
   - Flask atau FastAPI untuk web service
   - WebRTC untuk real-time video streaming

3.2 Bahan

Dataset Primer: Pengumpulan Data Real-time**.** Sebagai bagian dari kontribusi orisinal penelitian ini, dilakukan pengumpulan data primer melalui sesi interaksi real-time. Data dikumpulkan dari 10 partisipan dalam berbagai skenario percakapan yang mencakup interaksi kasual, dialog berbasis tugas, dan penceritaan emosional. Setiap sesi berlangsung antara 1 hingga 5 menit dan direkam dengan kualitas video 1080p pada 30 frame per detik, dilengkapi dengan sinkronisasi audio. Setiap frame dalam video kemudian dianotasi secara manual dengan label emosi, serta penanda konsistensi temporal yang mencerminkan kesinambungan ekspresi dari waktu ke waktu

Dataset Standar untuk Pelatihan **:** FER-2013, AffectNet, dan RAF-DB. Dataset FER-2013 terdiri atas 35.887 citra wajah grayscale berukuran 48x48 piksel, yang diklasifikasikan ke dalam tujuh kategori emosi dasar: marah, jijik, takut, senang, netral, sedih, dan terkejut. Dataset ini dibagi menjadi tiga subset: 28.709 citra untuk pelatihan, 3.589 untuk validasi, dan 3.589 untuk pengujian. FER-2013 diperoleh dari kompetisi *Facial Expression Recognition* di platform Kaggle, dan telah menjadi benchmark umum dalam pengujian algoritma pengenalan emosi berbasis gambar statis.

Selanjutnya, digunakan pula AffectNet, memuat lebih dari 400.000 citra wajah beranotasi. Citra-citra ini memiliki resolusi yang bervariasi, mulai dari 48x48 hingga 224x224 piksel, dengan format berwarna (RGB

Dataset ketiga, RAF-DB (Real-world Affective Faces Database), terdiri atas 29.672 gambar wajah yang dilabeli secara manual dengan kategori emosi tunggal, dan 3.954 di antaranya dilabeli dengan emosi majemuk. Citra-citra dalam dataset ini dikumpulkan dari internet, mencerminkan kondisi dunia nyata yang kompleks, seperti variasi pose, pencahayaan, ekspresi alami, serta kualitas dan resolusi gambar yang tidak seragam. Keberagaman ini menjadikan RAF-DB sangat berguna untuk melatih model agar lebih tangguh terhadap noise dan variasi lingkungan.

3.3 Cara Penelitian



Gambar 3. 1 Alur Pengerjaan Penelitian

Penelitian ini diawali dengan tahap Studi Literatur, yang bertujuan untuk memahami perkembangan terbaru dalam bidang pengenalan emosi wajah, khususnya pendekatan berbasis *deep learning* dan tantangan pada skenario real-time berdurasi panjang. Dari studi ini, dilakukan identifikasi celah penelitian (*research gap*) yang mendasari kebutuhan akan pendekatan yang lebih adaptif dan konsisten secara temporal.

Selanjutnya, dilakukan Identifikasi dan Persiapan Dataset, mencakup pemilihan dataset standar (seperti FER-2013, AffectNet, RAF-DB) serta pengumpulan data primer berbasis video real-time. Data yang terkumpul kemudian melewati tahap Preprocessing Data Wajah, seperti deteksi wajah, alignment, normalisasi, dan augmentasi, agar siap digunakan untuk pelatihan model.

Tahap berikutnya adalah Pengembangan Model CNN-LSTM, yang dirancang untuk menggabungkan kekuatan Convolutional Neural Network (CNN) dalam mengekstraksi fitur spasial dan Long Short-Term Memory (LSTM) untuk menangkap dinamika temporal ekspresi wajah. Setelah arsitektur dasar dikembangkan, dilakukan Penerapan Konsistensi Temporal, yang mencakup integrasi algoritma smoothing dan mekanisme pengawasan untuk menjaga stabilitas deteksi emosi selama interaksi berlangsung.

Agar sistem dapat berjalan secara efisien pada aplikasi real-time, dilakukan Optimasi untuk Real-time, seperti kompresi model, arsitektur pipeline, serta pengurangan latensi dan penggunaan memori. Setelah optimasi selesai, dilakukan Training dan Evaluasi Model, termasuk pelatihan baseline CNN, CNN-LSTM, dan model dengan kerangka konsistensi temporal, serta validasi melalui metrik akurasi dan konsistensi.

Model yang telah terlatih kemudian masuk ke tahap Integrasi dengan Chatbot, dengan membangun antarmuka API dan modul pengolahan video real-time yang memungkinkan chatbot memberikan respons berbasis emosi pengguna. Setelah integrasi, dilakukan Pengujian dan Evaluasi Sistem, baik dalam jangka pendek maupun panjang, untuk mengukur keandalan, performa real-time, dan pengalaman pengguna.

Akhirnya, penelitian ditutup dengan tahap Dokumentasi dan Finalisasi, yang mencakup penyusunan laporan eksperimen, analisis hasil, perbandingan dengan metode terkini, serta diskusi mengenai kontribusi dan keterbatasan sistem yang dikembangkan. Alur ini berakhir pada node End, sebagai penanda selesainya seluruh proses penelitian.

BAB 4. JADWAL PENELITIAN

Penelitian dilaksanakan mulai semester 2 hingga semester 3 tahun ajaran 2025/2026 sebagaimana tabel 4.1

No	Deskripsi Kegiatan	Tahun 2025 bulan ke						Tahun 2026 bulan ke					
		7	8	9	10	11	12	1	2	3	4	5	6
1	Studi Literatur												
2	Identifikasi dan Persiapan Dataset												
3	Preprocessing Data Wajah												
4	Pengembangan Model CNN-LSTM												
5	Penerapan Konsistensi Temporal												
6	Optimasi untuk Real-time												
7	Training dan Evaluasi Model												
8	Integrasi dengan Chatbot												
9	Pengujian dan Evaluasi Sistem												
10	Dokumentasi dan Finalisasi												
11	Penyusunan Paper Internasional												
12	Pengumpulan Paper Internasional												
13	Pra-pendadaran												
14	Pendadaran												
15	Yudisium												

DAFTAR PUSTAKA

[1] X. Ju, M. Li, W. Tian, and D. Hu, "EEG-based emotion recognition using a temporal-difference minimizing neural network," *Cogn Neurodyn*, vol. 18, no. 2, pp. 405–416, 2024, doi: 10.1007/s11571-023-10004-w.

[2] J. R. Saadon *et al.*, "Real-time emotion detection by quantitative facial motion analysis," *PLoS One*, vol. 18, no. 3, pp. e0282730-, Mar. 2023, [Online]. Available: https://doi.org/10.1371/journal.pone.0282730

[3] E. Paluzo-Hidalgo, R. Gonzalez-Diaz, and G. Aguirre-Carrazana, "Emotion recognition in talking-face videos using persistent entropy and neural networks," *Electronic Research Archive*, vol. 30, no. 2, pp. 644–660, 2022, doi: 10.3934/era.2022034.

[4] Y. Zhao and P. Krähenbühl, "Real-time Online Video Detection with Temporal Smoothing Transformers," 2022. [Online]. Available: https://arxiv.org/abs/2209.09236

[5] G. Bilquise, S. Ibrahim, and K. Shaalan, "Emotionally Intelligent Chatbots: A Systematic Literature Review," *Hum Behav Emerg Technol*, vol. 2022, pp. 1–23, Sep. 2022, doi: 10.1155/2022/9601630.

[6] A. John, A. M. C, A. S. Ajayan, S. Sanoop, and V. R. Kumar, "Real-Time Facial Emotion Recognition System With Improved Preprocessing and Feature Extraction," in *2020 Third International Conference on Smart Systems and Inventive Technology (ICSSIT)*, 2020, pp. 1328–1333. doi: 10.1109/ICSSIT48917.2020.9214207.

[7] J. Shan and S. Eliyas, "Exploring AI Facial Recognition for Real-time Emotion Detection: Assessing Student Engagement in Online Learning Environments," in *2024 3rd International Conference on Artificial Intelligence For Internet of Things (AIIoT)*, 2024, pp. 1–6. doi: 10.1109/AIIoT58432.2024.10574587.

[8] S. Pandey, S. Handoo, and Yogesh, "Facial Emotion Recognition using Deep Learning," in *2022 International Mobile and Embedded Technology Conference (MECON)*, 2022, pp. 248–252. doi:

10.1109/MECON53876.2022.9752189.

[9] D. Kollias, A. Schulc, E. Hajiyev, and S. Zafeiriou, “Analysing Affective Behavior in the First ABAW 2020 Competition,” in *2020 15th IEEE International Conference on Automatic Face and Gesture Recognition (FG 2020)*, 2020, pp. 637–643. doi: 10.1109/FG47880.2020.00126.

[10] S. Li, W. Deng, and J. Du, “Reliable Crowdsourcing and Deep Locality-Preserving Learning for Expression Recognition in the Wild,” in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2584–2593. doi: 10.1109/CVPR.2017.277.

[11] K. Zhang, Y. Huang, Y. Du, and L. Wang, “Facial Expression Recognition Based on Deep Evolutional Spatial-Temporal Networks,” *IEEE Transactions on Image Processing*, vol. 26, no. 9, pp. 4193–4203, 2017, doi: 10.1109/TIP.2017.2689999.

[12] X. Wang, R. B. Girshick, A. K. Gupta, and K. He, “Non-local Neural Networks,” *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7794–7803, 2017, [Online]. Available: https://api.semanticscholar.org/CorpusID:4852647

[13] J. Chen, Z. Chen, Z. Chi, and H. Fu, “Facial Expression Recognition in Video with Multiple Feature Fusion,” *IEEE Trans Affect Comput*, vol. PP, p. 1, Jul. 2016, doi: 10.1109/TAFFC.2016.2593719.

[14] A. Kumar, A. Kaur, and M. Kumar, “Face detection techniques: a review,” *Artif Intell Rev*, vol. 52, no. 2, pp. 927–948, 2019, doi: 10.1007/s10462-018-9650-2.

[15] A. Bhardwaj and S. Choudhary, “EMOTION-AWARE AI CHATBOTS: ENHANCING HUMAN-COMPUTER INTERACTION,” 2025. [Online]. Available: www.ijprems.com

[16] A. E. B. A. S. A. O. B. Amjad Rehman Muhammad Mujahid, “Comprehensive Review and Analysis on Facial Emotion Recognition: Performance Insights into Deep and Traditional Learning with Current Updates and Challenges,” *Computers, Materials & Continua*, vol. 82, no.

1, pp. 41–72, 2025, doi: 10.32604/cmc.2024.058036.